

Determinarea fluxului neuronal din semnale electroencefalografice (EEG) in timpul rostirii cuvintelor izolate

Proiect 3

Coordonator stiintific: -

Student 1: Chisalescu Bogdan

Student 2: Chivu Gheorghe-Iulian

date of today

1 Scopul lucrarii

1.1 Scopul

Prezenta lucrare urmareste dezvoltarea unei solutii software orientata catre agenti inteligenti, capabila sa poata determina/recunoaste fluxul neuronal bazandu-se pe o serie de semnale electroencefalografice. In cazul de fata, fluxul neuronal este determinat de rostirea cuvintelor izolate.

1.2 Solutia propusa

Pentru a indeplini scopul lucrarii, am propus dezvoltarea unui algoritm de inteligenta artificiala supervizat, din clasa retelelor neuronale. Arhitectura retelei neuronale ce dorim sa o dezvoltam este de tipul clasificatorului multi-clasa.


2 Semnalele EEG

Semnalele electroencefalografice (EEG) sunt o serie de monitorizari temporale asupra activitatii electrice a creierului uman. Activitatea ce este urmarita consta din fluctuatiile campului electromagnetic produs de activitatea sincronizata a populatiilor de neuroni din diverse sectiuni ale creierului. Inregistrarea si captarea semnalelor EEG este utila in analiza electroencefalografica deoarece stimuleaza abilitatea de a vizualiza si surprinde in timp schimbarile apraute atunci cand un subiect uman dezvoltă procese cognitive.

Pentru a putea capta semnalele EEG, se monteaza pe capul subiectului o casca ce contine o serie de dispozitive sensibile la fluctuatiile campului electric, numite electrozi. Subiectul este apoi instruit sa intretina anumite activitati cognitive, timp in care se inregistreaza activitatea neuronală. Electrozii sunt dispusi in asa fel incat sa fie acoperita o arie cat mai mare a creierului si sunt de obicei grupati astfel incat un grup de electrozi sa inregistreze activitatea unui lob cerebral. Fiindca semnalele captate au valori mici, de ordinul microvoltilor (μV) acestea sunt amplificate, mai apoi digitalizate si filtrate. Fiecare electrod corespunde unui canal electroencefalografic.



(a) Subiectul uman in timpul inregistrării EEG



(b) Amplasamentul electrozilor

Din punct de vedere spectral putem considera semnalele EEG ca fiind compuse din 5 game/benzi de frecventa: Delta (1-4 Hz), Theta (4-7 Hz), Alpha (7-12 Hz), Beta(12-30 Hz) si Gamma (30-100 Hz).




Figure 1: Benzile semnalelor EEG

3 Setul de date

Pentru aceasta lucrare ne-am folosit de setul de date pus la dispozitie de Departamentul de Stiinta Calculatoarelor a Universitatii din Toronto: The KARA ONE Database. Acest set de date a fost achizitionat in urma unui studiu bazat pe aceleasi principii ca cele descrise in sectiunea semnalelor EEG. O casca speciala a fost plasata pe capul subiectilor, ce sacneaza 64 de canale si are electrozii plasati dupa sistemul 10-20; toate datele au fost amplificate folosind un amplificator SynAmps RT si esantionate la o frecventa de esantionare $F_S = 1$ KHz. Timp de 30 pana la 40 de minute subiectii si-au imaginat rostirea dar au si rostit 7 foneme si 4 cuvinte.

In aceasta lucrare am preluat semnalele EEG filtrate ce au rezultat in urma studiului. Au rezultat astfel un numar de 993 de observatii si 64 de canale pentru fiecare observatie. Timpul alocat pentru o observatie a fost de 5 secunde. Stiind frecventa de esantionare de 1 KHz ne rezulta aproximativ 5000 de esantioane pentru fiecare canal.




Figure 2: O parte din canalele EEG ale unei observatii




Figure 3: Canalul 'CB2' al unei observatii intins pe durata de aproximativ 5 secunde

Avand la dispozitie toate datele necesare, putem construi structura pe care o vor avea datele de intrare ale clasificatorului. Numarul de observatii este de 993, iar numarul de canale EEG pentru fiecare observatie este de 64, avand in vedere ca la intrarea clasificatorului vom introduce cate o observatie, vom considera toate cele 64 de canale ca trasaturi, canalele fiind aici reprezentate de esantioanele lor. Un canal contine aproximativ 5000 de esantioane, insa acest numar nu este constant pe intreg setul de date. Considerand faptul ca, in timpul studiului subiectul a desfasurat aceeasi activitate cognitiva de mai multe ori in decursul celor 5 secunde ale unei observatii, am luat decizia de a prelua esantioanele de la indicele 499 pana la 4499, deci un numar total de 4000 de esantioane.

Cele 64 de canale, acum a cate 4000 de esantioane fiecare, vor fi liniarizate. In acest caz datele de intrare vor avea forma $(993 \times 4000 \cdot 64) = (993 \times 256,000)$, adica 993 de observatii a cate 256,000 de trasaturi.

4 Analiza Componentelor Principale

Deoarece datele de intrare sunt semnificative ca dimensiune, iar pentru aceasta lucrare am dispus de resurse relativ modeste de calcul, am luat decizia de a selecta doar canalele EEG pe care le-am considerat importante si mai apoi de a aplica o analiza a componentelor principale .

Canalele EEG pe care le-am considerat cele mai importante si de care am dispus in setul de date sunt urmatoarele: C5, C3, C1, CZ, C2, C4, C6, CP5, CP3, CP1, CPZ, CP2, CP4, CP6, P7, P5, P3, PZ, P2, P4, P6, P8, FC5, FC3, FC1, FCZ, FC2, FC4, FC6, F7, F5, F3, F1, FZ, F2, F4, F6, F8, AF3, AF4. In urma acestei selectii, din cele 64 de canale initiale vor ramane 40, ceea ce ne modifica structura datelor de la $(993 \times 256,000)$ la $(993 \times 160,000)$.

Analiza componentelor principale (PCA) este o metoda prin care se poate reduce dimensionalitatea datelor de intrare pastrand in acelasi timp cea mai mare cantitate din informatie. Algoritmul PCA reprezinta o modalitate de implementare a transformatei Karhunen–Loève. Pentru a reduce dimensionalitatea datelor dar si de a pastra cat mai multa informatie este necesara o transformare liniara cu proprietati de unitaritate, conservare si compactare a energiei. Transformata Karhunen–Loève ne ofera aceste proprietati. Avand la dispozitie un vector $\xi = [\xi(1), \xi(2), \dots, \xi(n)] \in \mathfrak{R}_{(1n)}$ reprezentand datele ce vor fi transformate, putem gasi reprezentarea vectorului in spatiul transformat ca fiind $\eta = L\xi$, unde L este o transformare liniara. Pentru a determina transformarea ne vom intoarce in spatiul original: $\tilde{\xi} = L^T \tilde{\eta}$, transformarea inversa este transpusa lui L datorita proprietatii de unitaritate iar $\tilde{\eta}$ este o aproximatie a lui η deoarece ne dorim ca in urma transformarii sa reducem din componentele vectorului η . In acest mod, putem determina eroarea de transformare in sensul erorii patratice medii ca fiind (...) Putem gasi transformarea L daca minimizam expresia erorii astfel incat $\epsilon = \epsilon_{min}$. Se poate demonstra matematic ca transformarea L este formata din vectorii proprii ai matricii de covarianta a vectorului ξ asezati pe coloana si ordonati descrescator dupa valorile proprii corespunzatoare. Transformata

Karhunen–Loève, găsește o bază vectorială de reprezentare astfel încât datele să se grupeze de-a lungul a cât mai multe axe pe care varianța este maximă. Pe acele axe pe care varianța nu este maximă, putem înlocui valorile din setul de date cu media axei respective, iar în cazul în care media a fost extrasă înaintea transformării, devenind astfel zero, putem elimina componentele respective.

În cazul nostru, vectorul ξ este un vector ale cărui elemente sunt la rândul lor vectori n -dimensionali, deci vom aplica algoritmul PCA asupra unei matrici, a cărei formă este determinată de setul de date. **Deoarece dispunem de sisteme de calcul cu capacitate de stocare relativ modestă, am luat decizia de a media cele 4000 de esantioane ale fiecărui canal EEG pe ferestre de câte 10 esantioane fără suprapunere.** În urma medierii, structura setului de date se modifică de la $(993 \times 160,000)$ la $(993 \times 16,000)$.

După multiple încercări eșuate, am ajuns la concluzia că setul de date este încă mult prea mare pentru a-l putea procesa cu puterea de calcul și capacitatea de stocare de care dispunem, astfel că am luat decizia de a clasifica semnalele pentru 2 clase în loc de 11 cum prevedea setul de date inițial. Astfel, structura datelor se modifică de la $(993 \times 16,000)$ la $(182 \times 16,000)$, dimensiunea de 182 fiind justificată de număr de observații însumat pentru cele două clase.